### Motivation

- Visuellen Überblick über Daten zu gewinnen
- Informationen gehen womöglich verloren

### Empirische Verteilungsfunktion

- Sei $X_1, \ldots, X_n$ eine Zufallsstichprobe mit Verteilung $F$. Die empirische Verteilungsfunktion ist

  $$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} 1_{\{X_i \leq x\}},$$

  wobei $1_{\{X_i \leq x\}} = 1$, wenn $X_i \leq x$, und $1_{\{X_i \leq x\}} = 0$ sonst.
- $$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \longrightarrow 0,$$
- Fundamentalsatz der [[Statistik]]
  - Approximation unbekannter Verteilungen möglich
  - wenn [[Stichprobe]] groß genug
- Beispiel
  - Skizzieren Sie die empirische Verteilungsfunktion der Daten:

    $$1.5 \quad 2.0 \quad 2.0 \quad 3.0 \quad 3.5 \quad 3.5 \quad 3.5 \quad 4.0.$$
  - 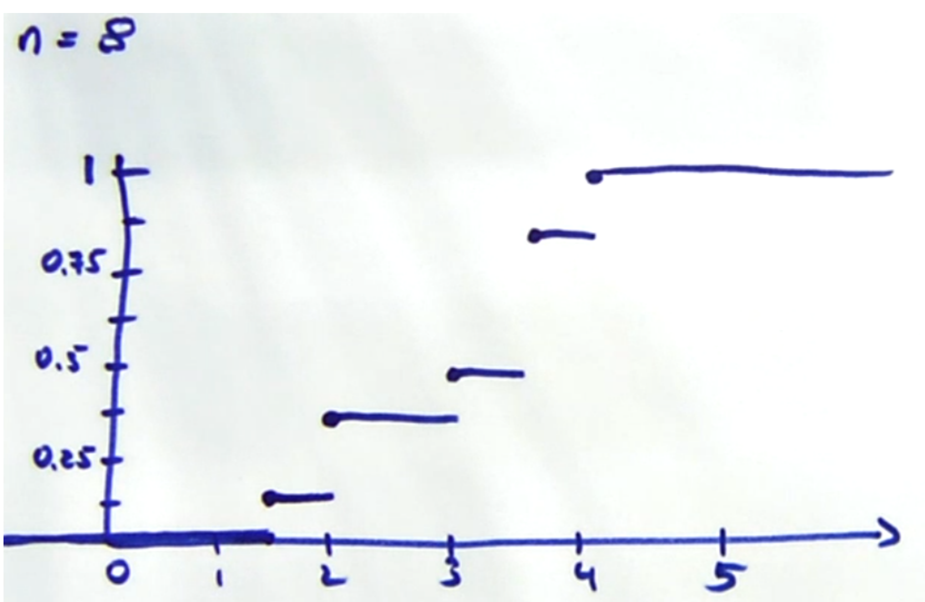

**Histogramm**

Die Konstruktion geschieht folgendermaßen:

1. Wähle $a \leq x_{(1)}$ und $b \geq x_{(n)}$.
2. Zerlege $[a, b]$ in $k$ äquidistante Intervalle

$$[a, a + \Delta] \quad (a + \Delta, a + 2\Delta] \quad \dots \quad (b - \Delta, b],$$

   wobei $\Delta = \frac{b-a}{k}$.
3. Sei $n_i$ die Anzahl der Beobachtungen im $i$-ten Intervall. Konstruiere über dem $i$-ten Intervall ein Rechteck der Höhe
   - $n_i \dots$ für absolute Häufigkeiten oder
   - $n_i/(n\Delta) \dots$ für relative Häufigkeiten.

- 
- simpler Schätzer für Dichtefunktion
- einfach verständlich
- abhängig von Auswahl der Parameter $a, b, k$

  Breite Intervalle verursachen einen höheren Informationsverlust. Schmale Intervalle ergeben oftmals ein unregelmäßiges Erscheinungsbild.
- 
- Beispiel
  - 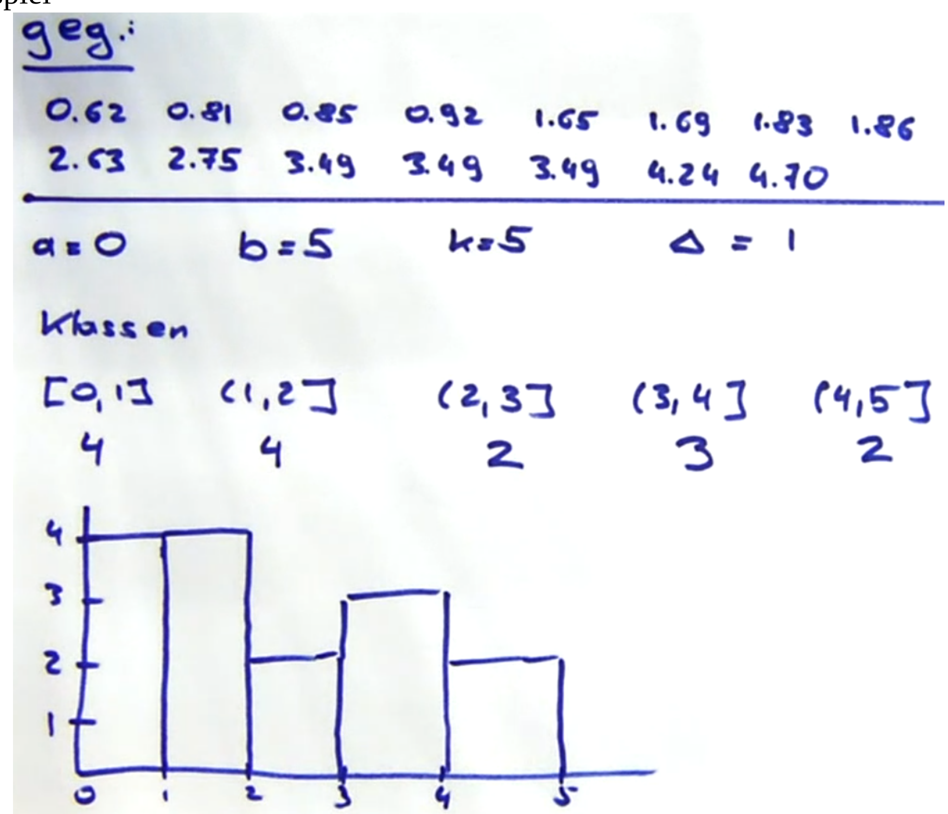

## Boxplot

- 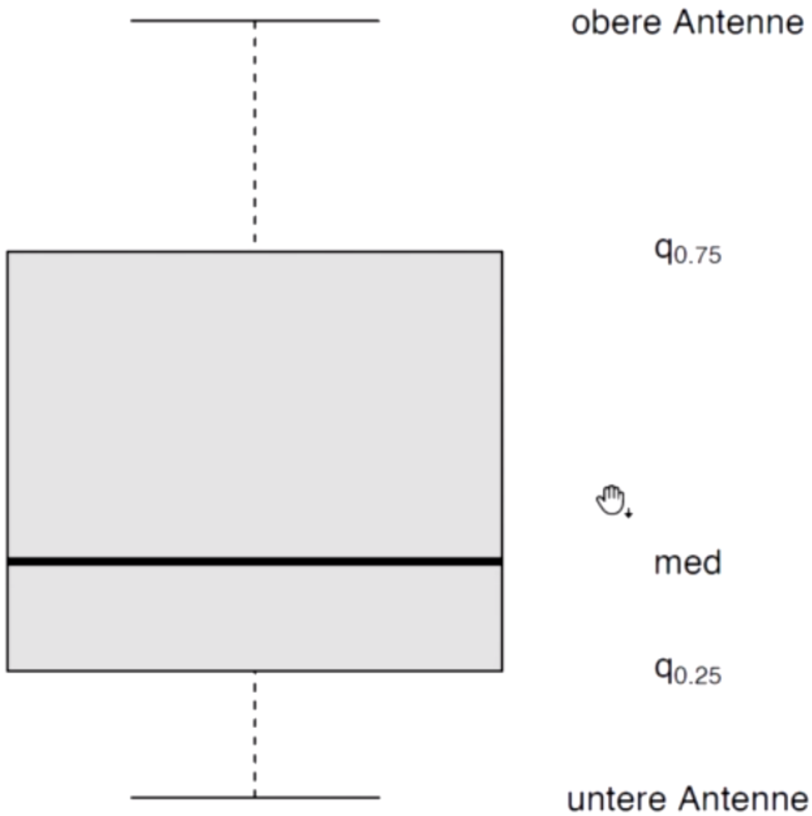


Die **Antennen** (Whisker) reichen bis zum kleinsten (größten) Wert, der nicht weiter als $1.5 \cdot \mathrm{iqr}$ unter (über) der Boxgrenze liegt.

- Ausreißer
  - Punkte außerhalb der Antennen
  - viele Ausreißer → womöglich nicht normalverteilt
- ideal für Vergleich unterschiedener Stichproben
- liefert schnellen Überblick

## Q-Q-Plot

- Quantil-Quantil-Plot
- vergleicht Daten mit Referenzverteilung
  - beurteilt Anpassung der Daten an theoretische Verteilung

Dabei plottet man die empirischen Quantile gegen die theoretischen Quantile der Referenzverteilung $F$.

Sei $0 \leq p_1 < p_2 < \cdots < p_n \leq 1$. Man plottet

$$(z_{p_1}, q_{p_1}) \quad (z_{p_2}, q_{p_2}) \quad \ldots \quad (z_{p_n}, q_{p_n}),$$

wobei $z_p$ dem theoretischen $p$-Quantil von $F$ entspricht.

- Annahme Normalverteilung
  - Q-Q-Plot weist auf Gegenteil hin